面向可靠图像编辑的诊断式评价方法研究

导师讨论与执行定稿

研究人 黄天志 htz

计划周期 2026 年 10 月 28 日至 2027 年 9 月 30 日

研究定位

本课题研究一个会主动查证的图像编辑评价器。它理解用户要求，指出具体疑点，选择最有价值的局部检查，并依据证据更新诊断。核心方法由可检验诊断学习与主动检查学习组成，最终向团队决策器提供可信的状态描述、保护条件和检查成本。

例如，用户要求把衣服改蓝。结果颜色正确，但胸前文字疑似变形。评价器选择放大文字并与原图核对，判断文字是否真的受损；恢复文字后应撤销这条诊断，只美化背景时应保持诊断，若修复又改回衣服颜色则报告新的问题。这个过程同时回答“哪里有问题”“判断依赖什么证据”和“下一步值得检查什么”。

统一研究问题

如何通过学习诊断成立、撤销与保持的条件，并主动选择具有辨别力的视觉证据，在有限检查预算下提高局部图像编辑诊断的准确性、可信度及其辅助决策的价值？

预期形成的贡献

一是以事实标签和修正、干扰对照共同监督诊断响应，建立可以用实验检验的诊断表示。二是依据当前疑点学习区域、属性与工具的检查价值，实现逐次取证和停止。三是通过真实编辑、跨编辑器与等成本团队接入实验，形成从诊断可靠性到决策收益的证据链。

执行承诺与资源摘要

导师确认后执行本路线，持续推进至 2027 年 9 月。个人研究按 300 小时、组内原任务按 60 小时作基准，合计 360 小时；学期内个人每周 3–4 小时，寒暑假每天 4–5 小时集中推进。建议支持一张 24GB 级 GPU 的共享使用，个人课题首期规划 80–180 GPU 小时，另预留适配与重跑额度。2027 年寒假完成模型 v0 和有效预实验，8 月底冻结主实验，9 月完成全部研究交付。

本文件统一研究与排期口径，取代此前个人方案中的时间预算；团队原文中的职责、规模和验收协议继续有效。

一 研究价值与创新落点

需要解决的实际问题

图像编辑评价不仅要发现整体质量下降，还要识别局部且重要的错误。例如文字改坏、对象身份变化、小部件丢失，可能被更漂亮的画面掩盖。另一方面，材质改变引起的反光或透射变化可能合理，简单差异检测容易误罚。决策器需要知道具体违反了什么要求、证据是否充分，而不仅是一项总分。

创新一 学习诊断如何响应可控变化

将学习单位从整图分数推进到可检验的局部诊断。对同一个错误，联合学习当前真实性、对应修正后的撤销、无关变化下的保持和新增错误的检出。这一监督结构使模型对其判断作出可核验预测，并能揭示“说是文字错误，实际依赖整体模糊”的证据错配。研究重点是这种监督能否在相同标注投入下提高真实诊断与迁移能力。

创新二 学习对当前疑点最有用的检查

检查策略读取已获得的证据，预测候选区域、属性和工具能带来多少正确诊断收益，再选择下一项检查。判断标准由信息量或解释长度转为独立标签上的误判减少与实际检查成本。模型同时学习何时已有足够证据、何时进一步检查不值得，以及何时保留未决状态。

两项贡献如何形成统一方法

诊断响应提供检查需要区分的条件；主动检查寻找支持或推翻这些条件的证据；新增证据更新诊断。两者共享对象、要求、证据和状态表示。最终验证目标是在相同成本下减少误报漏报，或以更少成本达到同等诊断质量，并为团队的动作价值预测提供更可靠输入。

三个检验假设

H1：相同骨干和人工投入下，加入诊断响应监督，比只学习当前事实或整体分数更可靠。H2：相同候选、工具和成本下，学习逐次检查价值优于固定清单、随机检查与直接工具路由。H3：保持队友的决策方案和整体预算可比时，加入诊断信息可提高最终成功率、降低严重损伤或节省调用成本。H1 与 H2 构成个人主成果，H3 构成团队联合验证。

二 与现有研究的具体衔接

比较依据为截至 2026 年 10 月 28 日核查的论文及前期文献指南。相关工作分别提供专用评分、局部定位、检查项、工具选择和反馈修正基础。本课题把贡献集中在诊断响应监督与状态依赖的检查价值学习，并通过同条件实验验证新增价值。

近邻工作	已有方法重点	本课题推进与对应实验
EditProbe [1]	中间层表示与参数高效适配用于质量评价	固定骨干比较事实监督与响应监督，测诊断而非仅分数相关性
ImageDoctor [2] 与 SpatialReward [3]	定位、推理及区域证据支持评价	检验局部诊断撤销与保持，并比较逐次取证和一次定位
RewardHarness [4]	演化工具技能库并由智能体选择调用	以可检验诊断状态训练边际检查价值，与同工具直接路由对照
CheckDistill [5]	将指令检查项知识蒸馏成高效评分模型	研究推理时新增观察的必要性与收益，测固定信息和动态信息条件
ReasonEdit [6] 与 EVR [7]	解释质量学习与假设证据验证	加入实物对照下的诊断响应约束，区分解释质量和判断机制
EditJudgeBias [8] 与 MDC [9]	质量保持偏差审计；属性编辑用于识别模型诊断	将审核后的修正与干扰用于编辑诊断训练，并测真实迁移
R³ Refiner [10]	学习反思反馈并由编辑器执行修正	主要学习取证与诊断，反馈以可验收条件输出，修复收益作扩展验证

上述差异决定实验必须同时控制模型容量、工具集合、标签投入与推理成本。论文比较采用其明确描述的目标和机制；实验中加入最接近且可运行的专用评价模型，以及同骨干的直接路由基线。

对整体论文叙事的贡献

团队研究“初始编辑后什么动作值得执行”。本课题补强其信息基础：用主动查证获得更可信的局部状态，帮助决策器分辨目标完成、非目标损伤与证据不足。整体叙事由“预测并选择动作”扩展为“可信状态感知支持预算内动作决策”，原决策任务和分工保持一致。

三 系统结构与诊断表示

输入为原图、用户指令和当前编辑结果。运行流程为：解析任务要求 → 提出候选疑点 → 建立初始证据 → 选择检查 → 更新诊断 → 停止或保留未决 → 输出结构化结果。

模块	固定实施方案	学习对象
要求解析	冻结多模态模型提取目标要求、保持要求和关联变化	首版使用固定提示与结构校验
候选区域	对象框、差异区域和覆盖性网格组成有限候选	检查头学习选择候选，不以单一掩码限制视野
诊断模块	局部表示、要求表示与已有证据融合	真实性、严重程度与诊断响应
检查模块	局部放大问答、OCR 核对、对象或边界核查三类	区域 属性 工具及停止的价值
输出模块	逐条问题、证据、置信度、保护条件、检查开销	诊断头输出结构；文本由固定模板表达

每条诊断的字段

记录诊断 ID、对象/区域、属性或关系、对应要求、当前错误概率、严重程度、证据位置、证据来源、工具失败状态、修正条件、应保持判断的无关变化，以及状态。状态统一为已支持、已反驳、待核验、无法确认。完成度、保持性和局部质量分别输出。

起步场景与覆盖范围

从改色与局部属性编辑中的文字、对象身份及边界保持启动，加入对象移除后的内容保持。材质反光、遮挡和透射作为合理关联变化的困难分层，用于研究误罚和不确定性；逐步扩展仍围绕相同诊断机制。个人数据先来自许可可用的公开结果及固定工具生成，不依赖团队动作表先完成。

检查执行约束

第一版每个样例最多保留 6 项候选检查，常规预算最多执行 2 项，并测试 0、1、2、3 项的成本曲线。工具结果缓存并附版本、耗时、可信度和失败标志。检查前后都允许保留未决；无法读取文字或配准失败不等价于内容正确。

四 学习目标与训练实施

可检验诊断学习

固定骨干提取原图、结果、局部区域和指令表示，训练小型融合模块与诊断头。对每条诊断构造当前结果、对应修正结果、无关干扰结果，部分加入修正伴随新损伤的混合结果。训练损失由事实分类、修正响应、无关稳定与新损伤检出组成；各权重在开发集选择后冻结。

事实分类用人工或审核标签约束当前判断；修正响应要求对应错误概率下降，并以修正后的实际标签为准；稳定项只约束确实不影响该诊断的干扰；混合结果分别撤销旧错误并识别新错误。采用独立事实标签避免稳定项产生“永远正常”的退化解。置信度通过开发集校准，未决阈值与覆盖率一同报告。

主动检查价值学习

先冻结已训练的诊断模块，离线执行候选检查。对每个状态和候选，用同一独立标签计算“检查前诊断损失减去检查后诊断损失”，再扣除实测检查成本惩罚，形成价值监督。训练排序或回归头预测此值。推理时只使用当前证据、候选描述和预算，不访问标签或未执行检查的结果。

首版从一步排序学习开始，再对预算不超过 3 项的短序列采样训练状态。每获得一项证据就更新状态并重新排序。加入停止候选，预测净收益为负或预算耗尽时停止；未决诊断保留并可转人工。通过两步组合检查分析互补证据，确定一步收益近似的适用范围。

实现次序与模型选择

优先采用可获得中间表示的 3B 级开源视觉语言骨干，例如 Qwen2.5-VL-3B [11]；固定模型修订号、视觉分辨率与提示。先缓存表示训练轻量模块。如果事实判别本身受表示能力限制，再进行小范围 LoRA 适配，之后重新冻结骨干进行归因实验。适配是实现优化，研究问题保持不变。

诊断反馈与修复收益的位置

核心输出已经包含需要恢复、必须保护、允许变化和验收依据，可直接供决策器使用。固定修复器下比较普通反馈与诊断反馈，作为主实验完成后的应用扩展；评价器训练仍以真实诊断和取证价值为主。修复收益预测与动作选择由队友负责，避免将同一个学习目标重复实现。

五 数据构造与人工投入

数据单位是一组共享原图和指令的编辑结果及诊断对照，不把同源变体计作独立样本。先进行 20 组试标，寒假扩大到 60–100 组；年度基准为约 300 组，按 180 训练、40 开发、80 独立测试规划。按源图先划分，再生成变体，实际规模以学习曲线与标注测时修订。

数据部分	构造方式	用途
真实结果	公开编辑结果或固定编辑器生成；至少两个编辑器来源	事实诊断与真实迁移
对应修正	局部人工校验修正或筛选实际成功修正	学习撤销对应诊断
无关变化	质量改善或其他区域变化，审核其不影响目标诊断	学习证据相关性与稳定性
混合与指令对照	修好旧错但产生新错；同类变化在不同指令下核验	学习更新与合理变化边界
检查轨迹	离线缓存有限候选检查与顺序状态	学习检查价值和停止

每组平均 3–4 个结果，约 900–1200 个图像结果实例。80 组测试以真实编辑结果为核心，并对其中适合的样例构造审核后响应对照；跨编辑器留出作为明确分层。公开数据必须记录原图来源、许可和编辑器，无法识别同源关系的数据不进入严格独立测试。

标注内容与工时

采用短结构标签：要求是否满足、错误区域/属性、严重程度、证据是否可读、对照是否有效和分歧原因。避免逐图撰写长推理链或像素级掩码。300 组每组平均 6 分钟，主标约 30 小时；试标、协议、构造审核、仲裁与清单整理约 25 小时，合计本人数据预算 55 小时。此速度在 20 组试标后测定。

一位助手独立复核 80 组测试及部分训练抽样，预留约 10–15 小时，另计其时间；分歧通过共同核对和导师必要复核解决。独立测试保留两份原始判断与仲裁记录。个人测试复核与团队规定的两位组外盲评是不同安排，不相互替代。

防止对照伪线索

检查贴回边缘、纹理、配准与分辨率是否引入额外差异；对修正有效性和无关变化性质单独标记。训练与测试分开干预实现方式，保留真实修正结果。分别报告真实样例和人工对照性能，以判断学到的是诊断关系还是构造痕迹。

六 实验矩阵与结果验收

检验	比较方案	主要读数
H1 诊断响应	相同骨干：事实监督；事实加响应监督	事实错误率、修正撤销、无关误翻转、新错检出
H2 主动检查	随机；固定清单；直接路由；学习策略；全量检查参考	成本与质量曲线、达到相同质量所需成本
两模块协同	基础；仅响应学习；仅主动检查；完整方法	相同预算下收益及互补性
泛化与鲁棒性	未见源图、留出编辑器、干预方式留出、工具故障	真实诊断误差、合理变化误罚、风险覆盖率
H3 团队接入	原输入；附加诊断输入，保持决策训练设置可比	原成功率指标、严重损伤、总成本、保持动作比例

评价原则与统计

个人主指标采用逐诊断宏平均 F1 与每组诊断错误率，并分开报告误报与漏报；响应指标包括有效修正后的正确撤销率、无关变化下错误翻转率、新损伤检出率。使用人类标签作为主要依据，不以本模型分数增加证明自身改善。所有响应指标同时给当前事实正确率，防止恒定输出取巧。

按源图进行聚类 bootstrap 并给 95%置信区间，重复训练 3 个随机种子，报告均值与变化范围。小型寒假试点用于可行性与效应估计，主实验前根据方差和目标精度调整测试量。组内功效分析及原主检验保持原协议，与个人指标分别记录。

强基线与成本口径

运行一个可复现的专用编辑评价模型作为外部强基线。直接视觉语言评价同时测试简短直接判分提示与结构化诊断提示，两者使用相同图像和预算。归因实验固定骨干、输入与工具；外部大模型另列资源条件。记录初始解析、候选生成、检查、模型推理和必要人工复核成本，离线训练成本另报。全量检查是昂贵参考，不假定其一定最准确。

完成标准

交付数据与审核协议、两个可学习模块、完整比较与消融、真实和跨编辑器测试、代码与个人报告。研究结论以证据说明在哪些条件有效及其原因；性能目标在寒假预实验后预注册。个人课题独立验收，团队联合收益作为进一步验证，不等待队友实验才能完成个人报告。

七 算力与设备申请

建议导师支持共享单卡 24GB 级 GPU、32–64GB 主存及 200–300GB 工作存储。首选冻结 3B 级骨干与缓存特征训练；较大专用基线或高分辨率推理可短时使用 48GB 级资源或 API。GPU 由实验室排期提供即可，无需独占整年。以下是规划量，依据首批 20 组测速更新。

阶段	预计资源	GPU 小时预算
环境与 20 组先导	单卡 16–24GB；限制视觉 token 与批量	5–10
表示及候选证据缓存	24GB，顺序运行模型与工具	20–50
轻量诊断与策略训练	缓存表示；CPU 或单卡 8–16GB	10–20
基线 消融 留出验证	24GB 共享卡，3 种子及两类提示	30–70
失败重跑与复现	24GB	15–30
冻结骨干路线合计	个人课题，不含团队动作表生成	80–180
必要时参数高效适配	优先 24–48GB，短序列与小批量	另加 40–100

估算依据与容量控制

按约 1200 个结果实例、每例最多 6 项候选缓存，约 7200 次检查；若实测每次 5–20 秒，仅该部分约 10–40 GPU 小时，加初始解析、工具、基线与重跑形成上表区间。调用速度受图像大小、生成长度和设备影响，首批实测后替换假设。按 GPU 占用时间计机时，排队不算本人工作时间。

3B 模型仅参数的 BF16 存储量约 6GB，实际还需视觉编码、激活、缓存和运行开销；因此以 24GB 作舒适规划，而非把参数大小当显存需求。控制每次图像数量和 token，固定输入规格后再比较性能。LoRA 需求由实测决定，不承诺某显卡必然适配全部配置。

资源不足时的同路线实施

先缓存小规模证据并在 CPU 训练小头，等待共享 GPU 完成批量推理；更大教师只用于少量分歧分析。API 服务可辅助基线，但诊断表示学习优先保留本地开放权重。个人补充生成只用于数据缺口，单独记账；团队原动作表生成机时维持原预算。

经费占位：API 和必要租算 800–1800 元，助手复核 400–800 元，存储与重跑 200–400 元，合计 1400–3000 元；属于申请预留，不是实时供应商报价。获得实验室资源后相应减少现金支出。

八 时间投入与推进里程碑

时间	个人小时	组内预留	明确产物
现在至 2026 年 12 月	32	10	11 月基线、12 月 20 组试标及协议
2027 年 1 月假期前	12	4	数据与训练管线、小型验证集
寒假约 4 个有效周	80	10	60–100 组数据、诊断 v0、预实验报告
2027 年 3 至 6 月	52	16	4 月底主动检查 v0；6 月底主实验协议
2027 年 7 至 8 月	104	14	主实验、泛化与对接；8 月底冻结
2027 年 9 月	20	6	统计、报告、复现、交付
合计	300	60	基准 360 小时，规划区间 320–400 小时

学期内个人平均每周 3–4 小时，组内原职责另按协作节点安排。寒暑假每天 4–5 小时、每周 5 个工作日，包含组内与个人；寒假 90 小时需约 4 周，暑假 118 小时需约 5 周。具体假期日期按校历落位，目标日期保持不变。

寒假形成有效成果的执行顺序

第一周完成数据审核与基线输入；第二周完成直接评价和固定检查比较；第三周训练事实监督与响应监督两版诊断模型；第四周完成留出检验、失败分析和候选检查收益测量。提交比较表、失败清单、脚本及 5–8 页报告，时间为寒假结束前，最迟 2027 年 3 月 7 日。

年度工时分配

个人 300 小时包括：文献综述 50、环境工具 25、数据与标注 55、诊断学习 50、主动检查 40、验证统计 50、报告复现 30。阅读与实验同步，寒假前读 15–20 小时，其后按实验问题回读。原 30 篇指南继续使用，完成全部阅读不是启动条件。

截止控制

6 月 30 日冻结主实验协议，8 月 15 日完成核心实验，8 月 31 日冻结结果，9 月 15 日完成报告统计，9 月 30 日交付复现材料。9 月用于收尾而非新增算法。每两周记录实际工时和可验收产物，优先解决影响下一里程碑的问题。

九 团队职责与接口

成员或模块	保持的职责	与本课题的连接
何劲 控制与机制	核验冻结编辑器、实现动作、构造扰动与动作表	提供开发结果和动作元数据；个人实验可先独立用公开数据
孙彧 预测与决策	动作改善破坏成本预测、预算选择和等成本对照	消费结构化诊断；决定实际改图动作
黄天志 原团队职责	评分细则、自动分校准、组外盲评、统计与功效	原协议和交付保持，优先按团队节点提供
黄天志 个人课题	诊断响应监督、主动检查价值学习、独立验证	提供诊断状态和成本，形成独立研究报告

保留原团队评价规模

开发集约 300 例双人校准，测试覆盖 A 的 560 任务及 B 抽样 160 任务，共 720 个评分单元，每单元两位组外评分者。原估计总评分 34–164 人时，另计仲裁、手册与培训。该数值是多人合计，不等于本人 60 小时；本人组织协调、所承担校准和统计均计入组内投入。组外人员由原团队流程落实。

接口与联合实验

输入包含 task_id、原图与结果路径、指令、编辑器版本、诊断预算；输出包含逐条 diagnoses、对象区域、要求类型、概率与严重程度、证据引用、未决状态、保护条件、检查序列、耗时与模型版本。不输出队友六动作的最佳动作标签。时间成本包含初始解析与实际检查。

先交协议、字段样例与统计脚本，团队开发结果到达后立即开展原校准。个人模块成熟后，在同数据切分和总成本下比较原输入与附加诊断输入；若需要重训决策器，保持架构与训练设置可比并单独记录。最终盲评继续用原独立协议，学习评价器不兼任唯一裁判。

并行推进与交付约定

团队原评价路线随原计划运行，个人模型开发不阻塞队友。团队截止更早则先完成团队节点；如共同成果需 2027 年 9 月交付，应同步确认 8 月底前冻结及 9 月盲评统计排期。个人独立实验和报告可按本方案自行完成。论文中分别说明数据、方法与实验贡献，个人立项如实注明团队提供的数据和支持。

十 执行规则与导师讨论事项

确定主线后的调整原则

固定研究问题、两项学习模块和独立评价目标。允许按实验结果调整骨干规模、损失权重、候选检查数量、数据比例与训练细节；这些属于实施迭代。更换研究问题、取消核心模块或新增完整修复器开发，需要与导师明确讨论后决定。定期查新用于改进基线与论证，不因出现相似文章而频繁换方向。

困难如何在原路线内解决

若事实判断不足，先检查标签和表示，再适配骨干；若合成收益不迁移，改善对照有效性并增加真实结果；若固定检查很强，研究成本区间和疑点异质性，检验策略何时有用；若工具没有有效证据，保留失败状态并测人工证据上限。每项迭代都围绕同一个可靠诊断与取证问题。

先完成主线 再拓展应用

完整研究储备包括合理变化依赖、竞争假设、指令对照、不确定性、工具故障、数据效率、可验证反馈、保护条件、修复收益、跨修复器和多轮历史。前六项融入数据或主实验；反馈与保护条件先以结构输出实现；反馈收益学习、跨修复器和多轮历史在核心完成后推进。这样的顺序保留发展空间，并使 2027 年 9 月可交付。

与导师确认的具体支持

请导师重点讨论：诊断响应与主动检查的联合问题是否适合作为大研主线；真实数据来源和核心基线选择；单卡 24GB 共享机时与必要适配额度；测试复核和标注安排；寒假、4 月底、暑假前及 8 月底四次阶段汇报。讨论后将建议写入版本记录并开始执行。

阶段材料与最终交付

寒假交预实验报告和可运行原型；4 月底交主动检查模型与初步消融；暑假交完整实验表与团队接口；9 月交个人研究报告、数据说明、标注规范、模型与配置、复现脚本及统计附录。模型和数据按许可发布，受限数据提供索引与复现流程。论文初稿可与团队共同组织，接收时间不占研究完成期限。

参考文献与实施资源

[1] Evaluating Image Editing with LLMs: A Comprehensive Benchmark and Intermediate-Layer Probing Approach。2026，arXiv v2。

论文或资源入口

[2] ImageDoctor: Diagnosing Text-to-Image Generation via Grounded Image Reasoning。ICLR 2026。

论文或资源入口

[3] SpatialReward: Bridging the Perception Gap in Online RL for Image Editing via Explicit Spatial Reasoning。2026，arXiv v4；作者标注 ICML 录用。

论文或资源入口

[4] RewardHarness: Self-Evolving Agentic Post-Training。2026，arXiv v2；此处采用预印本题名。

论文或资源入口

[5] CheckDistill: Adaptive Checklist Distillation for Efficient Distributional Reward Modeling in Image Editing。2026，预印本。

论文或资源入口

[6] ReasonEdit: Towards Interpretable Image Editing Evaluation via Reinforcement Learning。2026，预印本。

论文或资源入口

参考文献与实施资源续

[7] Evaluation-Verification Reward for Consistent Multi-Reference Image Editing。2026，预印本。

论文或资源入口

[8] Do MLLM Judges Judge the Edit? Auditing Bias in Image Editing Evaluation with Verified Quality Preservation。2026，预印本。

论文或资源入口

[9] Model Diagnosis and Correction via Linguistic and Implicit Attribute Editing。CVPR 2025。

论文或资源入口

[10] Benchmarking and Evolving Reason-Reflect-Rectify for Reflective Visual Generation。ICML 2026。

论文或资源入口

[11] Qwen2.5-VL-3B-Instruct 官方模型卡。实施候选；显存机时为本方案估算。

论文或资源入口

配套阅读：同目录《htz_必读 10 篇与了解 20 篇_文献指南和综述提纲_20261028.docx》。本执行稿以现有 30 篇清单为研究依据，后续按方法迭代补充近邻工作。