黄天志研究排期修订方案

组内原任务保持不变 学期轻量推进 寒暑假集中实验

执行区间 2026 年 10 月 28 日至 2027 年 9 月 30 日

本次修订结论

前版的团队 30–40 小时、12 周学习阶段和 2027 年 10 月收尾安排不再适用。组内职责、实验规模、盲评标准及与队友的协作节点按原计划执行；个人课题调整投入节奏，2027 年 8 月 31 日前冻结主实验，9 月完成统计、报告、代码和复现交付。研究效果不能保证，但必须按期限交付可核验结果，包括负结果。

个人研究预算 280–340 小时，基准 300 小时；组内职责仍按前版 40–60 小时估计，基准 60 小时，合计 320–400 小时，基准 360 小时。40–60 小时只是本人时间估计，不是削减团队职责的上限。若原任务实际超出，应先消耗个人扩展余量，不能降低组内协议要求。

时期	个人投入安排	组内投入
学期内	平均每周 3–4 小时；考试周可降至 0–2 小时	另计，暂留平均 1–2 小时响应窗口；关键节点集中投入
寒暑假	预设每天 4–5 小时，每周 5 个工作日，即 20–25 小时；不按每天全年满负荷排	当周先满足原团队节点，剩余时段推进个人实验
2027 年 9 月	个人约 20 小时，主要整理与交付	为原盲评统计和最终协作保留集中时间

寒假先假设能安排 4 个有效集中周，暑假能安排约 5 个有效集中周；这是容量假设，不是学校已公布校历。寒暑假每天 4–5 小时按个人与组内工作合计理解，不额外叠加。假期实际可用周数确认后只移动日期，不将最终交付推迟到 10 月。

保持的研究主线

个人工作仍包括可检验诊断学习，以及评价器学习下一步检查哪里、检查什么和何时停止。固定基础模型，使用有限工具和公开或自建小规模数据。组内仍由队友负责改图动作与动作价值决策；个人检查策略不替代队友的编辑动作选择。

阶段预算与硬截止

阶段	个人小时	团队预留小时	到期产物
现在至 2026 年 12 月	32	10	11 月跑基线；12 月完成 20 组试标和数据协议
2027 年 1 月假期前	12	4	训练脚本、对照生成、冻结小型验证集
寒假集中阶段	80	10	60–100 组试点数据，诊断模型 v0 及比较报告
2027 年 3 至 6 月	52	16	主动检查原型、消融和真实数据补充
2027 年 7 至 8 月	104	14	主实验、跨编辑器验证、团队输入对照
2027 年 9 月	20	6	封存统计、报告、复现、全部交付
合计	300	60	360 小时

表中团队小时仅为个人日程占位，不能取代原组内里程碑。队友提前需要协议、标签或校准结果时立即响应，相关小时从后续阶段前移。不得要求队友等个人模型成熟才进行主实验。暑假 104+14=118 小时，可用 5 周、每周约 24 小时承担；寒假 80+10=90 小时，可用 4 周、每周约 22.5 小时承担。

明确的检查点

2026 年 11 月 15 日前：跑通至少一种现成评价基线，并整理 5–10 个真实失败案例。12 月 15 日前：完成 20 组试标、标注测时和首版诊断响应检查。2027 年 1 月 15 日前：具备可训练的数据与脚本，考试周可降低新增任务，但不将首次运行拖到假期末。

寒假结束前完成试点验收，最迟 2027 年 3 月 7 日提交报告；若实际假期更早结束，则相应提前。4 月 30 日前完成有限候选主动检查 v0；6 月 30 日前冻结主实验协议；8 月 15 日前完成核心实验；8 月 31 日前冻结结果；9 月 15 日前完成报告与统计；9 月 30 日前完成归档和交付。

上述日期为研究执行承诺目标，不代表学校大研申报或结项日期。论文投稿或接收不作为 9 月完成全部研究工作的定义。

寒假必须拿到的有效成果

寒假成果不是只搭好环境，也不要求预先保证性能提升。应有可复查的数据、运行结果和下一阶段决策依据。11 月至寒假同步阅读与实验，前两周优先读 EditProbe 与 ImageDoctor 及一篇专用评价基线，随后按当前实验问题补读；30 篇不设为开工前置条件。

集中周	个人工作与可验收产物
第 1 周	审核数据和干预有效性，形成 60–100 组试点的可用清单；每组含原结果及必要修正或无关干扰对照
第 2 周	跑通直接评价与固定局部检查基线，统计真实性、对应修正后的撤销和无关变化下的稳定性
第 3 周	训练轻量诊断 v0；比较只用事实标签和加入响应监督，统一骨干、工具和数据条件
第 4 周	在独立留出真实样例上检验并分析失败；缓存候选检查结果，评估哪些检查确有诊断收益，写 5–8 页报告

数据量是试点目标，不是成功保证：20 组试标后按标注速度调整。按源图划分训练、开发和留出，所有同源变体必须同一分区；尽量给留出 20–30 组真实编辑样例。小样本结果只用于方向判断，不据此宣称统计显著或跨编辑器充分泛化。合成干预必须审核，不能把贴回瑕疵当成目标错误线索。

有效成果的最低证据

至少交付一张方法比较表、一份分类型失败清单、一套可重复运行脚本和一份导师讨论报告。报告说明：哪类误判存在；响应监督是否有初步帮助；假设失败时原因是什么；下一步主动检查能获得什么额外证据。没有提升也可以是有效结果，但仅有截图或环境部署不算完成。

个人 300 小时怎样分配

文献与综述 50 小时，工具环境 25 小时，数据构造及本人标注 55 小时，诊断学习 50 小时，主动检查 40 小时，独立验证与统计 50 小时，报告复现 30 小时。阅读分散到全年，寒假前约 15–20 小时，余下围绕实验回读。30 篇阅读深度分层，基础学习超出时从 40 小时范围余量调整。

组内原任务保障与风险处置

依据《指代式图像编辑空间控制决策》原文，黄天志负责评价与统计：评分细则、自动分校准、组外盲评、统计与功效，交付评分手册、校准报告、盲评数据和统计附录。本版不改队友职责、主检验和六动作设置。

保持原协议：开发集约 300 例双人校准；测试主结论覆盖 A 的 560 个任务与 B 的 160 个抽样任务，共 720 个评分单元，每单元两名组外评分者；原估算总评分 34–164 人时，另计仲裁与培训。开发集三人轮换和组外测试双评都来自原方案，本版不新增转移你的工作来换取个人空闲。

团队其他评分者的工时不计入你个人 360 小时，但组织、培训、仲裁协调和本人承担的开发标注应计入你的团队时间。目前只有一位帮手，不能等同于已落实两名组外评分者；应尽早落实第二人，并在正式盲评前至少四周排期。

对接顺序

现在先提供评分协议、接口字段和统计脚本；团队第一批开发输出到达即校准；决策器训练前提供符合原协议的可信标签和置信度；冻结配置后执行原封存测试及盲评。个人模型成熟后作为附加输入做消融，个人模型不稳定时团队仍使用原评价路线，不能让新模型成为新的必经依赖。

保证截止的方式

每两周检查一次个人与团队实际用时；6 月底后不新增研究分支。8 月 15 日后只补关键失败或复现，不扩充方法。若进度落后，先取消修复闭环扩展、多轮历史、复杂变化关系和额外工具部署，保留诊断学习、有限候选主动检查、必要基线与真实留出验证。

寒假试点失败则在 3 月内集中诊断数据或监督问题；4 月底仍无法训练时，主动检查限定为小规模候选监督排序，保留学习问题，不扩到强化学习。算力受限则冻结骨干、离线缓存。个人负结果如实交付，不以反复调试推迟 9 月结项。

完成组内最终交付依赖队友数据和共同冻结节点：若团队原排期尚未落到日历，需共同确认 8 月底前主实验冻结、9 月内评价完成。个人可以承诺自己接口和报告就绪，不能单方面保证队友交付。此项日历对齐不改变原分工；原团队截止更早则以更早日期执行。